

Instituto Tecnológico de Aeronáutica - ITA
Inteligência Artificial para Robótica Móvel - CT-213
Aluno: Danilo de Farias Matos

Relatório do Laboratório 7 - *Imitation Learning* com Keras

1. Breve Explicação em Alto Nível da Implementação

Iniciei a implementação usando por base o código já feito para a análise do efeito da regularização, foi necessário apenas fazer os ajustes propostos para os tamanhos de entrada e a quantidade de neurônios (75,50,20) que cada camada deveria ter e zerar a regularização. Também foi necessário fazer ajustes na função de ativação para que ela se tornasse uma leakyRelu para as duas primeiras e uma linear simples na última.



Por fim, adaptei a função de custo para ser o erro quadrático e foi possível efetuar o treinamento da rede com 30.000 épocas, conforme proposto.


Ademais, após ficar tentando várias vezes usar o google colab e acabar perdendo o treinamento, decidi implementar também um sistema de salvamento dos pesos já alcançados pelas épocas anteriores explorando a biblioteca "ModelCheckpoint" do Keras, que deixou a implementação bem simples.

2. Figuras Comprovando Funcionamento do Código


2.1. Função de Classificação *sum_gt_zeros*



Lambda = 0







Lambda = 0.002







2.2. Função de Classificação XOR



Lambda = 0



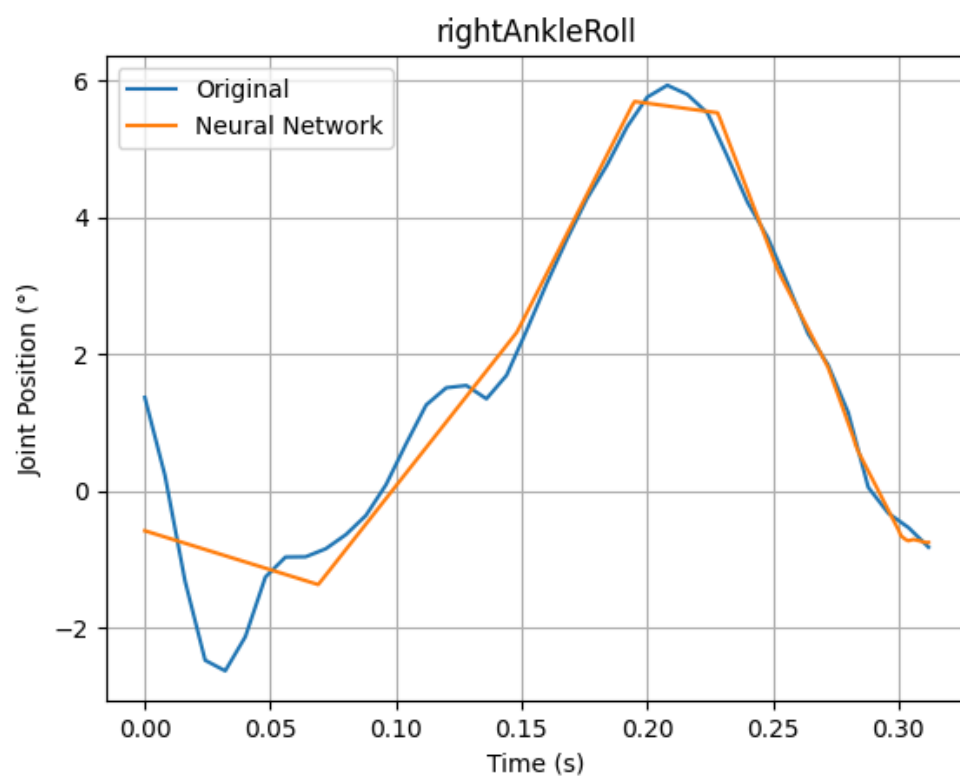
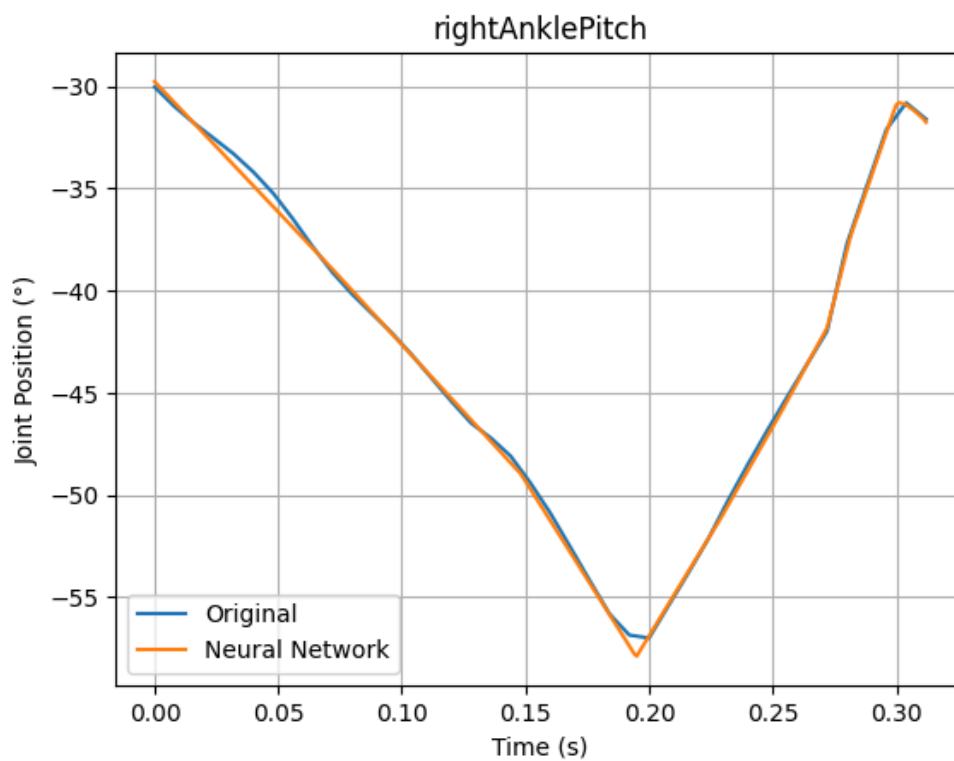



Lambda = 0.002


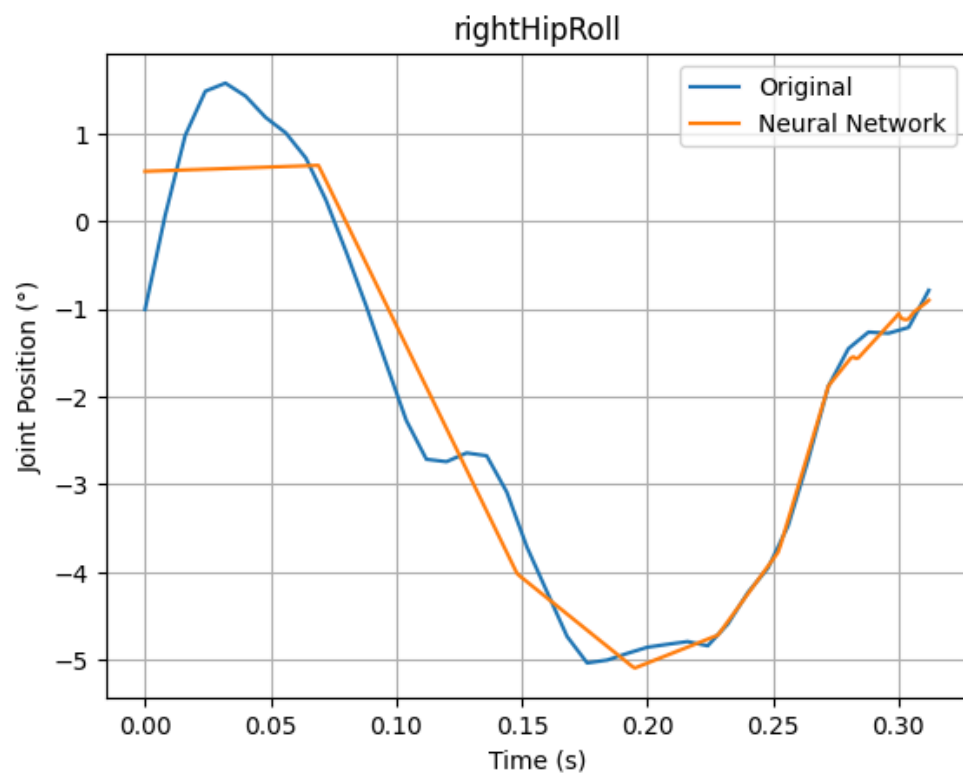




2.3. *Imitation Learning*







3. Discussões

Primeiramente, observei nos exemplos de teste com as funções “sum_gt_zero” e “xor” que as implementações que possuíam valor em lambda, ou seja, possuíam regularização, apresentaram resultados melhores que as que não possuíam regularização.

Isso pode ser observado quando olhamos para os gráficos que mostram os limites de decisão da rede neural. Quando usamos regularização, não conseguimos observar nenhum “ponto laranja” dentro da área que classificaria certamente aquele ponto como “azul” e vice-versa.

Outra observação que achei interessante é que a regularização pareceu acelerar a velocidade com que a rede neural minimiza o custo.

Já para a parte do imitation learning, observei que o aumento da quantidade de épocas e o uso de um batch com o tamanho total do dataset (evitando a prática de divisão do dataset em terços de treinamento, validação e teste) induziu a rede a efetuar um overfit no conjunto de dados que, para o nosso caso específico (imitar de maneira mais fidedigna possível as posições de um outro robô) faz sentido.